Exploitation de données électorales avec `Python`

Evaluation intermédiaire *Python pour la data science* (mi-semestre 2026)

Lino Galiana
Insee
lino.galiana@insee.fr

Mots-clés : Evaluation, Python

Wednesday, March 18, 2026

L'objectif de ces exercices est de vous amener à explorer la richesse des données électorales fines avec `Python`. Vous pourrez ultérieurement aller plus loin pour essayer de relier les résultats de vote à des variables socioéconomiques disponibles à la même échelle.

! Consignes générales

- Envoyer par mail avant le **31 mars 2026** votre dépôt `Github` à votre chargé de TD.
- Le dépôt Github `Github` doit contenir au moins un *notebook* `Jupyter` présentant des éléments d'analyse et de visualisation (dataframe, figures, tableaux, etc.). Il est possible (et même recommandé) de reporter une partie du code dans des modules séparés du principal *notebook* (des fichiers `.py` importés dans le notebook principal): cela rendra votre travail plus lisible.
- Une attention importante sera accordée à la lisibilité de votre code et des *outputs* (tableaux ou figures).
- Le code doit être **entièrement reproductible**. C'est-à-dire que si votre chargé de TD clique sur le bouton `Run all`, le notebook doit s'exécuter de bout en bout.

Le code d'import des données est directement mis à disposition pour vous permettre de démarrer les exercices.

```
import pandas as pd
df = pd.read_csv(
  'https://www.data.gouv.fr/fr/datasets/r/182268fc-2103-4bcb-a850-6cf90b02a9eb'
)
```

code_departement	libelle_departement	code_commune	libelle_commune	prenom	nom	voix
01	Ain	1	L'Abergement-Clémenciat	Nathalie	ARTHAUD	3
01	Ain	2	L'Abergement-de-Varey	Nathalie	ARTHAUD	2

1. Explorations générales

Question 1

Créer ou mettre à jour les variables suivantes:

- `code_commune`: En utilisant la variable déjà existante et le département, remplacer la valeur `code_commune` pour constituer un vrai code commune. Par exemple, pour Montrouge, vous devriez obtenir `92049`.
- `candidat`: créer une colonne avec le `prenom` et le `nom` mis ensemble, en n'oubliant pas de mettre un espace. Ne pas éliminer les bulletins abstentions, blancs ou nuls, nous allons les exploiter ultérieurement.

Question 2

Compléter la phrase suivante grâce à `Python`:

En 2022, il y avait XXXXX candidats à l'élection présidentielle

Note: Attention aux votes non exprimés et aux abstentions

Utiliser cette *f-string* comme réponse:

```
f"En 2022, il y avait {candidats} candidats à l'élection présidentielle."
```

Table 1. – Réponse à la question 3

Elections ⊠⊠

Résultats du premier tour (🗓 *10 avril 2022*)

Candidat	Nombre votes (total)	Score (% votes exprimés)
Emmanuel MACRON	9 783 058	27.85%
Marine LE PEN	8 133 828	23.15%
Jean-Luc MÉLENCHON	7 712 520	21.95%
Éric ZEMMOUR	2 485 226	7.07%
Valérie PÉCRESSE	1 679 001	4.78%
Yannick JADOT	1 627 853	4.63%
Jean LASSALLE	1 101 387	3.13%
Fabien ROUSSEL	802 422	2.28%
Nicolas DUPONT-AIGNAN	725 176	2.06%
Anne HIDALGO	616 478	1.75%
Philippe POUTOU	268 904	0.77%
Nathalie ARTHAUD	197 094	0.56%

Question 3

Calculer les scores nationaux de chaque candidat. Représenter dans ce tableau, pour chaque candidat, le nombre de voix et le pourcatage des votes exprimés (c'est-à-dire en retirant abstentions et votes non exprimés).

Représenter cela dans un *dataframe* ou, pour avoir tous les points, dans un tableau mis en forme via `great_tables` (il n'est pas obligatoire d'aller aussi loin dans la mise en forme mais essayez d'obtenir un beau tableau tout de même).

Note: vous pouvez contrôler vos résultats obtenus avec cette page

Le résultat attendu de cette question est similaire à Table 1.

Table 2. – Exemple de résultat à la question 4

code_departement	candidat	votes	score
11	Marine LE PEN	64027	30.14%
11	Emmanuel MACRON	43104	20.29%
11	Jean-Luc MÉLENCHON	42039	19.79%
11	Éric ZEMMOUR	18434	8.68%
11	Jean LASSALLE	12382	5.83%
11	Valérie PÉCRESSE	7350	3.46%
11	Yannick JADOT	6322	2.98%
11	Anne HIDALGO	6166	2.90%
11	Fabien ROUSSEL	5622	2.65%
11	Nicolas DUPONT-AIGNAN	4206	1.98%
11	Philippe POUTOU	1748	0.82%
11	Nathalie ARTHAUD	1026	0.48%

2. Comparaison des scores départements aux moyennes nationales.

On va essayer d'étudier la territorialité de certains votes. Pour cela, nous allons étudier la manière dont certains candidats sont surreprésentés dans les résultats par rapport à leur moyenne nationale.

Question 4

Créer un *dataframe* nommé `score_departements` stockant, pour chaque département, le nombre de vote obtenu pour chaque candidat et le score (en %).

Par exemple, vous devriez obtenir un résultat similaire à Table 2 pour l'Aude (département n°11). Créer une cellule permettant de vérifier cela.

Question 5

Refaire le lien avec le niveau national pour comparer le score départemental avec le score national. Nommer ce *dataframe* `score_departements`, nous allons le réutiliser par la suite.

Par exemple, vous devriez obtenir le résultat Table 3 pour l'Aude (département n°11). Créer une cellule permettant de vérifier cela (dans Table 3 seulement trois candidats sont représentés mais faites le pour tous).

Table 3. – Exemple de résultat à la question 5

code_departement	candidat	votes_departement	score_departement	votes_national	score_national
11	Marine LE PEN	64027	30.14%	8133828	23.15%
11	Emmanuel MACRON	43104	20.29%	9783058	27.85%
11	Jean-Luc MÉLENCHON	42039	19.79%	7712520	21.95%

Question 6

Créer une variable `surrepresentation` qui compare, en relatif, les scores nationaux et départementaux.

Par exemple, si un candidat a un score de 30% dans un département mais de 15% ailleurs, la valeur de `surrepresentation` sera égale à 100 (%).

Question 7

Créer une fonction pour représenter une figure similaire à Figure 1 pour un candidat donné des principales surreprésentations (en valeur absolue) par département.

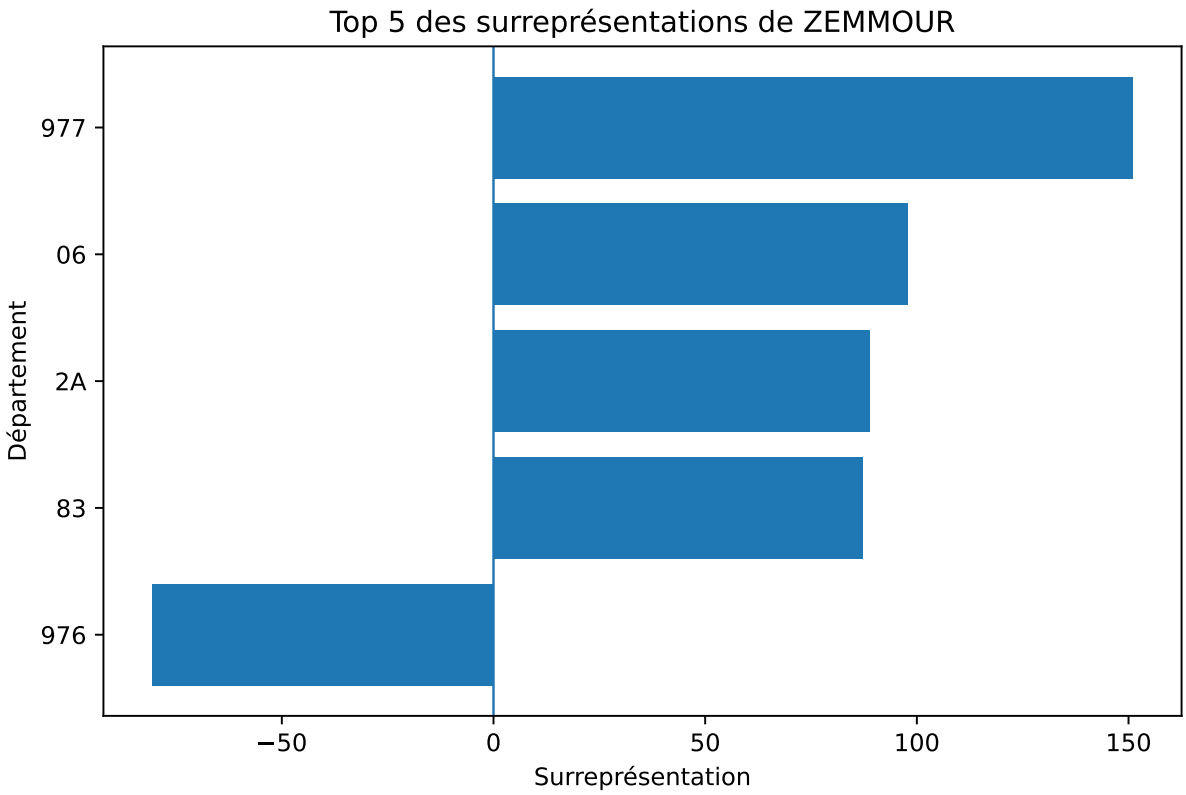

Figure 1. – Exemple d'illustration pour la question 7

3. Un peu de cartographie

Pour cette partie, vous pouvez récupérer le fond de carte des départements grâce au code ci-dessous:

```
from cartiflette import carti_download

departement_borders = carti_download(
      values = ["France"],
      crs = 4326,
      borders = "DEPARTEMENT",
      vectorfile_format="geojson",
      simplification=50,
      filter_by="FRANCE_ENTIERE_DROM_RAPPROCHES",
      source="EXPRESS-COG-CARTO-TERRITOIRE",
      year=2022)
```

Question 8

Faire une fonction permettant de restreindre `score_departements` en fonction d'un candidat. Commencer par tester sur Marine Le Pen (créer un nouvel objet, ne pas écraser `score_departements` nous allons l'utiliser à nouveau !).

Faire une jointure au fond de carte des départements et effectuer une carte de la représentation.

Vous devriez obtenir des cartes similaires à Figure 2, Figure 3 ou Figure 4

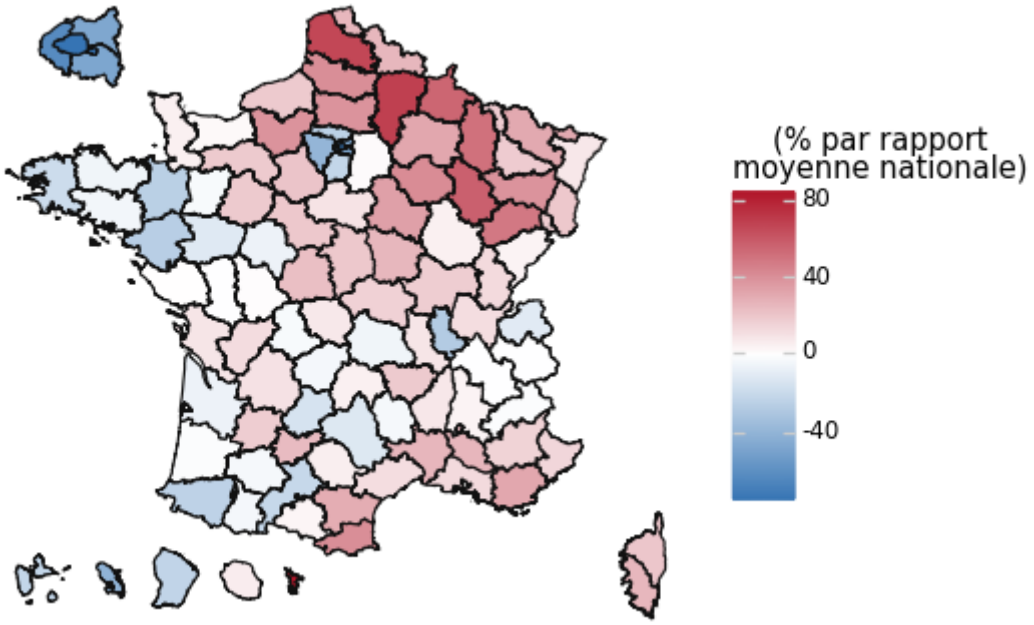

Figure 2. – Exemple de carte obtenue à la question 8 (Marine Le Pen)

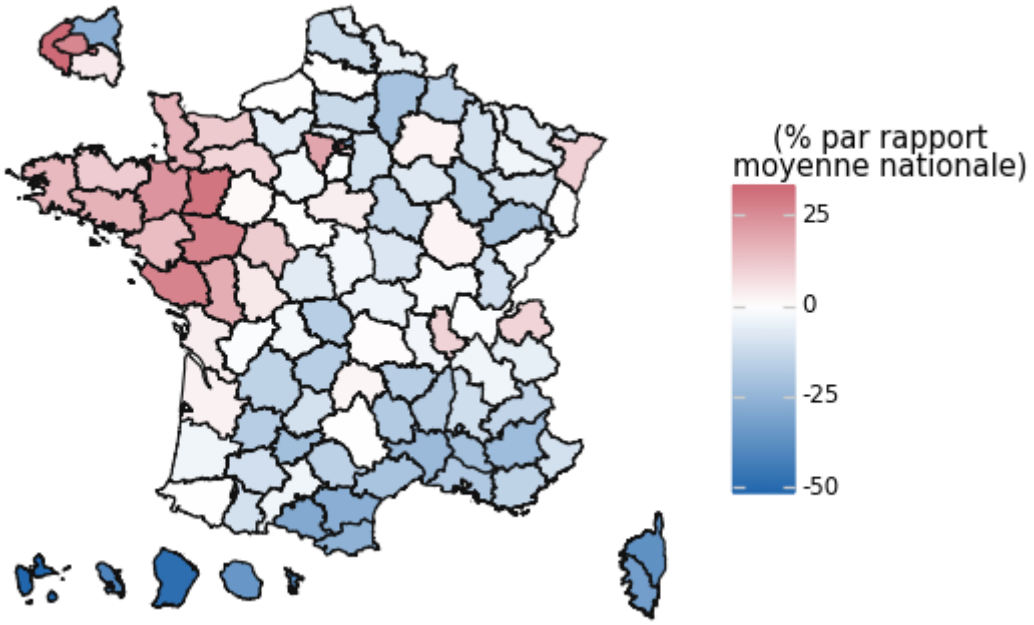

Figure 3. – Exemple de carte obtenue à la question 8 (Emmanuel Macron)

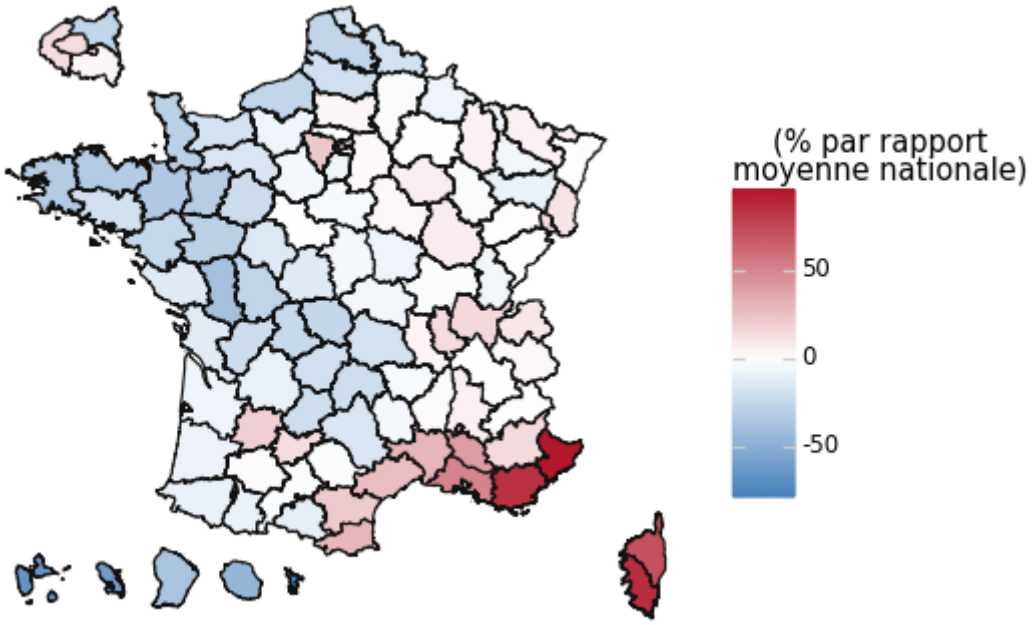

Figure 4. – Exemple de carte obtenue à la question 8 (Eric Zemmour)